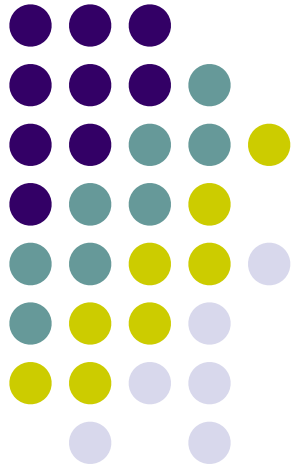
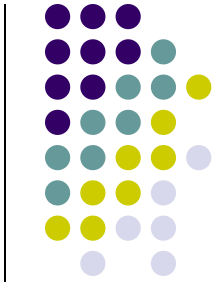
Inteligência Computacional

Prof. Celso Camilo

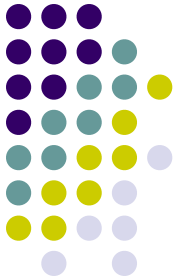


Introdução - Conteudo



- O que é Inteligência Computacional (IC) ?
- Técnicas Inteligentes
  - Algoritmo genético
  - Redes Neurais
  - Logica Fuzzy
  - Swarm Intelligence
  - ...
- Áreas de Aplicação

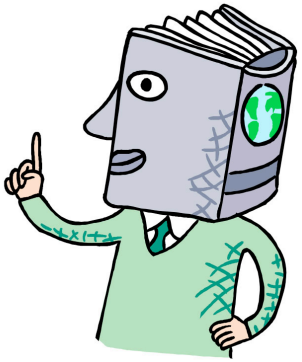
Introdução



O que é Inteligência ?

O que você considera inteligente ?



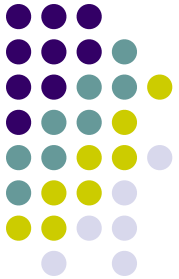






Introdução

O que é Inteligência ?

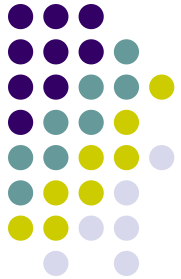


“capacidade de aprender, apreender e interpretar ”

Dicionário Aurélio

Introdução

O que é Inteligência ?



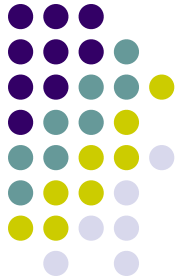
“A habilidade de aprender ou entender ou tratar com situações novas.”

“A habilidade de aplicar o conhecimento para manipular um ambiente ou pensar abstratamente como avaliado por critérios objetivos (como testes).”

Webster’s New Collegiate Dictionary,1975

Introdução

O que é Inteligência ?

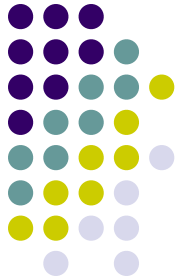


“Inteligência é a capacidade do sistema adaptar seu comportamento para encontrar seus objetivos em uma faixa de ambientes.”

David Fogel (1995)

Introdução

O que é Inteligência ?



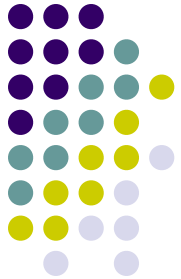
- No livro do Andreas ele relata outras fontes que incluem aspectos como creatividade, habilidade, emoção e intuição na definição de inteligência

Andreas Book (CI – An Introduction)

Intelligence Is…

- Capacity to learn from experience
- Ability to adapt to different contexts
- The use of metacognition to enhance learning

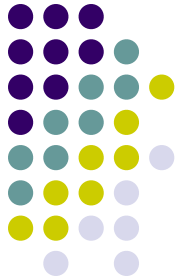
Emotional Intelligence



- Mayer & Salovey (1997)

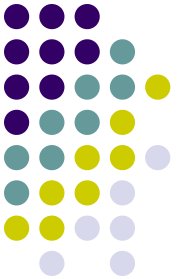
  "The capacity to reason about emotions, and of emotions to enhance thinking. It includes the abilities to accurately perceive emotions, to access and generate emotions so as to assist thought, to understand emotions and emotional knowledge, and to reflectively regulate emotions so as to promote emotional and intellectual growth"

Social Intelligence



- Ability to get along with others
- Knowledge of social matters
- Insight into moods or underlying personality traits of others

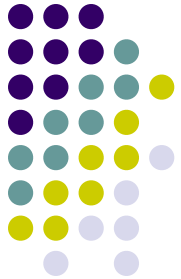
Introdução



Os computadores podem ser inteligentes ?

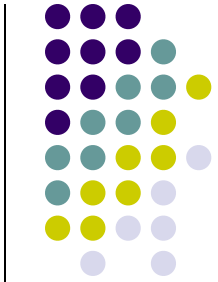
Introdução

Os computadores podem ser inteligentes ?



- Em meados de 1900, Alan Turing acreditava que não há nada que a mente faz que um computador bem projetado não possa fazer.
- Depois de 20 anos, o seu pensamento ainda é considerado visionario.
- Em 1950 Turing publicou o seu teste para medir a inteligência do computador – Teste de Turing.

Introdução

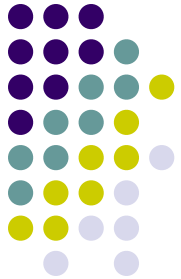


Teste de Turing

- O teste consiste em uma pessoa fazer perguntas pelo teclado para uma outra pessoa e um computador.

- Se o interrogador não conseguir distinguir a máquina da pessoa, então o computador é inteligente.

Introdução



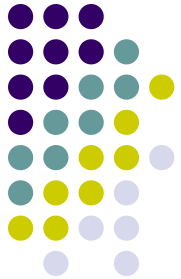
- O que é Inteligência Computacional (IC) ?

"Técnicas e sistemas computacionais que imitam aspectos humanos, tais como: percepção, raciocínio, aprendizado, evolução e adaptação".

"A Inteligência Computacional busca, através de técnicas inspiradas na Natureza, o desenvolvimento de sistemas inteligentes que imitem aspectos do comportamento humano, tais como: aprendizado, percepção, raciocínio, evolução e adaptação."

ICA-Puc-RIO

Introdução



- O que é Inteligência Computacional (IC) ?

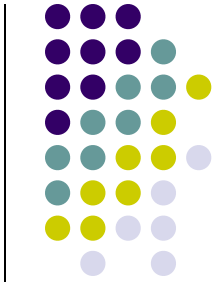
"Redes Neurais, Algoritmos Genéticos, Sistema Fuzzy, Programação Evolucionária e Vida Artificial são os blocos construtores da Inteligência Computacional."

IEEE Transactions on Neural Networks

"IC geralmente descreve métodos de computação que podem ser usados para adaptar soluções para novos problemas sem depender explicitamente do conhecimento humano"

David Fogel - 1995

Introdução



- Inspiração na Natureza

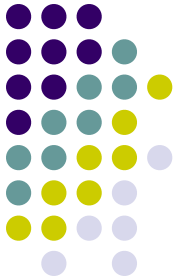
Lógica Fuzzy - processamento linguístico

Redes Neurais - neurônios biológicos

Algoritmos Genéticos – evolução biológica

Sistemas Híbridos – aspectos combinados

Suporte a Decisão



- *Lógica Fuzzy*
- *Redes Neurais*
- *Algoritmos Genéticos*
- *Sistemas Híbridos*

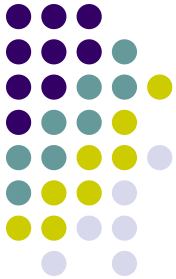
- Aquisição de Conhecimento
- Previsão
- Otimização
- Controle
- Planejamento
- Data Mining
- Análise de Risco
- Detecção de Fraude

Introdução – Áreas de Aplicação





Introdução – Áreas de Aplicação



Alguns Projetos Desenvolvidos no ICA	
Setor	**Tema**
Ensino	Software Educacional para o Ensino de Sistemas Inteligentes
Energia	Previsão de Carga Elétrica por Redes Neurais: Mensal, Horária, Pico, Intervalos 10min Sistema Híbrido de Detecção e Diagnóstico de Falhas em Sistemas Elétricos Otimização de Despacho por Algoritmos Genéticos Otimização da Alocação de Capacitores em Sistemas Elétricos Controle de Cheias em reservatórios de usinas hidrelétricas Reconhecimento de Descargas Parciais em Equipamentos Elétricos
Petroquímico	Simulação de Forno de Craqueamento da Refinaria REDUC Utilizando Redes Neurais Sensor Virtual por Redes Neurais para a Medição de Intemperismo na Produção do GLP Otimização da Distribuição Combustíveis por Algoritmos Genéticos
Industrial	Sistema Inteligente de Reconhecimento de Imagens Bidimensionais Redes Neurais Aplicadas a Ensaios Não-Destrutivos de Materiais Condutores Sistemas Inteligentes Aplicados ao Reconhecimento de Voz Otimização e Planejamento da Produção Controle e Navegação de Robos Compressão de Imagens Digitalizadas por Redes Neurais
Comercial	Otimização do Planejamento de Horários/Alocação de Salas por Algoritmos Genéticos Reconhecimento de Dígitos Manuscritos por Redes Neurais para Leitura de Código Postal Reconhecimento de Caracteres Impressos (OCR) Utilizando Redes Neurais Previsão da Demanda de Lubrificantes Descoberta de Padrões em Bancos de Dados Comerciais Classificação/Segmentação de Clientes a partir de Informações Cadastrais em BD
Econômico/ Financeiro	Planejamento de Fluxo de Caixa Inteligente (FCI) Gerência de Carteira de Investimentos (Risco x Retorno) por Algoritmos Genéticos Previsão de Indicadores Financeiros por Redes Neurais Previsão do Índice Bovespa por Redes Neurais Modelos Híbridos de Previsão de Séries Temporais
Meio Ambiente	Previsão de Precipitação Pluviométrica na Área do Nordeste por Redes Neurais

Introdução – Áreas de Aplicação



Empresa	Sistema Inteligente	Técnicas
Souza Cruz	• Fluxo de Caixa Inteligente	• Alg. Genéticos
Eletrobrás	• Previsão do Consumo Mensal de Energia Elétrica	• Redes Neurais
Embratel	• Classificação de Clientes	• Redes Neurais • Alg.Genéticos
PUC-Rio	• Alocação de Salas de Aula • Avaliação da Produção Científica	• Alg. Genéticos • Lógica Fuzzy
Cia. Vale do Rio Doce	• Projeto S4: Planejamento e Otimização de Embarque de Minério no Porto de Tubarão • Projeto S4-V2: Planejamento e Otimização de Embarque de Minério Porto de Tubarão • Projeto Monitor: Fase de Especificação	• Alg. Genéticos • Oracle • UML
Petrobrás	• Inferência de Propriedades de Derivados do Petróleo • Gestão Conhecimento Instrumentação e Automação • Análise de Alternativas de Investimento em Projetos de Exploração e Prospeção de Petróleo sob Incertezas Técnicas e de Mercado – Fases 1, 2 e 3 • Otimização da Quantidade e Localização de Poços Petrolíferos para o Desenvolvimento de um Campo de Petróleo sob condições de certeza – Fases 1 a 3 • Análise Econômica de Projetos de E&P sob Incerteza de Campos Inteligentes • CONFPETRO: Sistema de Caracterização da Confiabilidade Humana para a Área de Petróleo	• Redes Neurais • Sistemas Especialistas • Alg. Genéticos • Neuro-Fuzzy • UML • CORBA
ScoreTec	• Software Vox Score para a aquisição, gerenciamento e análise da voz, para triagem de recursos humanos	• SQL / UML • Redes Neurais
Light	• Sistema Inteligente Apoio à Decisão na Recuperação de Perdas por Fraude e na Caracterização dos Fraudadores • Identificação e Prevenção de Inadimplência para o Mercado de Grandes Clientes	• Redes Neurais • Neuro-Fuzzy • Alg. Genéticos



Algoritmos Genéticos

Conceitos Básicos

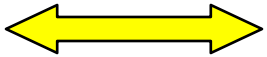
- Algoritmo de *busca/otimização* inspirado na *seleção natural* e reprodução *genética*.

Conceitos Básicos

- Algoritmo de *busca/otimização* inspirado na *seleção natural* e reprodução *genética*.

- Combina *sobrevivência do mais apto* e *cruzamento* aleatório de informação

Analogia com a Natureza

Evolução Natural  **Alg. Genéticos**

- Indivíduo
- Cromossoma
- Reprodução Sexual
- Mutação
- População
- Gerações
- Meio Ambiente

- Solução
- Representação
- Operador Cruzamento
- Operador Mutação
- Conjunto de Soluções
- Ciclos
- Problema

Qual a finalidade de Algoritmos Genéticos?

Algoritmos Genéticos empregam um processo *adaptativo* e *paralelo* de busca de soluções em *problemas complexos*.

Qual a finalidade de Algoritmos Genéticos?

- **Adaptativo**
  - informação corrente influencia a busca futura
- **Paralelo**
  - várias soluções consideradas a cada momento
- **Problema Complexo**
  - de difícil formulação matemática ou com grande espaço de busca (grande número de soluções)

Problema Complexo

Exemplo:

Maximizar $\mathbf{f(x) = x^2}$: encontrar $x \in (0 \ldots 2^L - 1)$ para f(x)=máx

2^L	**Número de Pontos no Espaço**	**Tempo de Busca** 10^9 inst/seg

Problema Complexo

Exemplo:

Maximizar $\mathbf{f(x) = x^2}$: encontrar $x \in (0 \ldots 2^L - 1)$ para f(x)=máx

2^L	**Número de Pontos no Espaço**	**Tempo de Busca** 10^9 inst/seg
L=3	8	< 1 seg

Problema Complexo

Exemplo:

Maximizar **f (x) = x²** : encontrar x ∈ (**0 ... 2 ^{L} -1**) para f(x)=máx

2^L	**Número de Pontos no Espaço**	**Tempo de Busca** 10^9 inst/seg
L=3	8	< 1 seg
L=10	1024	< 1 seg

Problema Complexo

Exemplo:

Maximizar $\mathbf{f(x) = x^2}$: encontrar $x \in (0 \ldots 2^L - 1)$ para f(x)=máx

2^L	**Número de Pontos no Espaço**	**Tempo de Busca** 10^9 inst/seg
L=3	8	< 1 seg
L=10	1024	< 1 seg
L=30	1 bilhão	1 seg

Problema Complexo

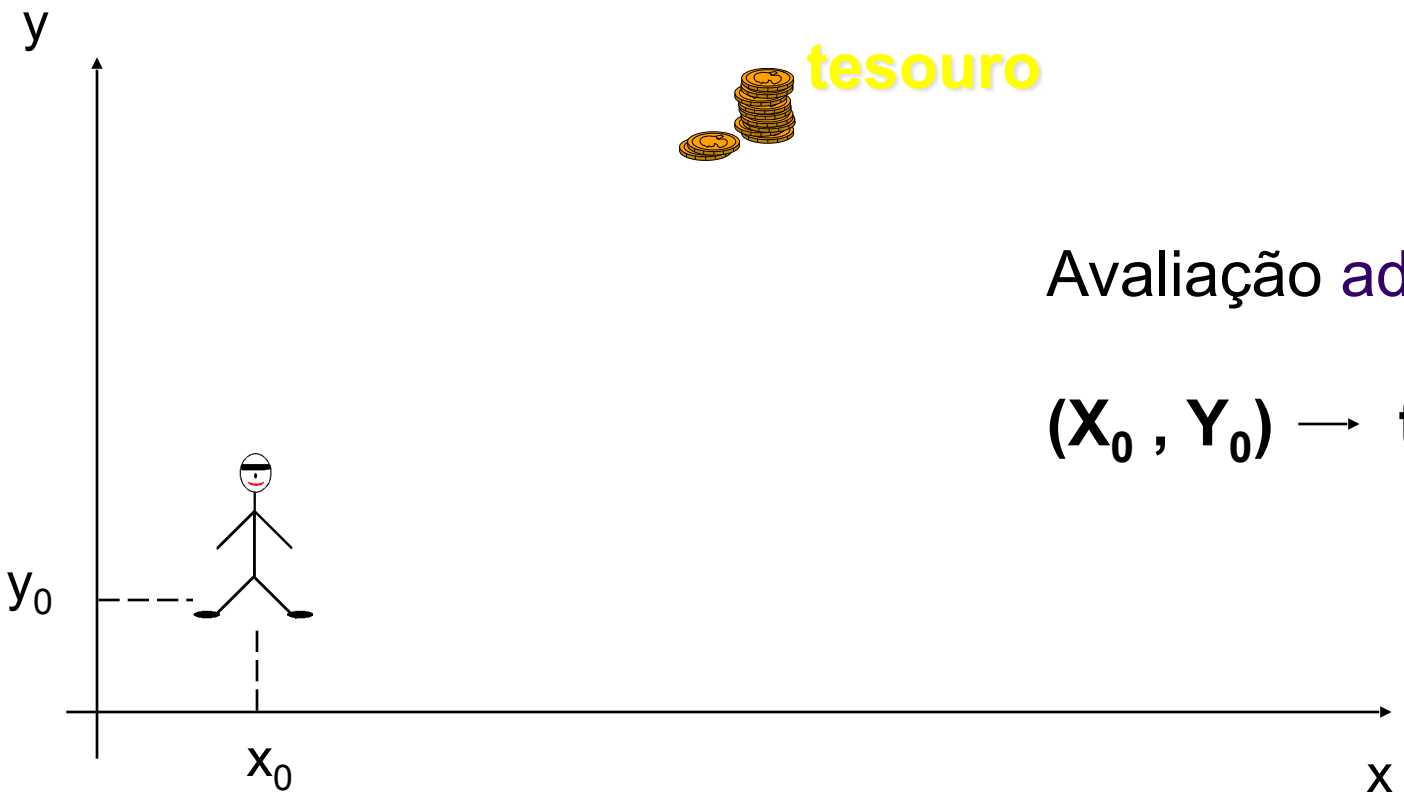
Exemplo:

Maximizar $f(x) = x^2$: encontrar $x \in (0 \ldots 2^L - 1)$ para f(x)=máx

2^L	**Número de Pontos no Espaço**	**Tempo de Busca** 10^9 inst/seg
L=3	8	< 1 seg
L=10	1024	< 1 seg
L=30	1 bilhão	1 seg
L=90	10^{27}	15 bilhões de anos

Problema da Cabra Cega

Busca de objetivo escondido em uma área

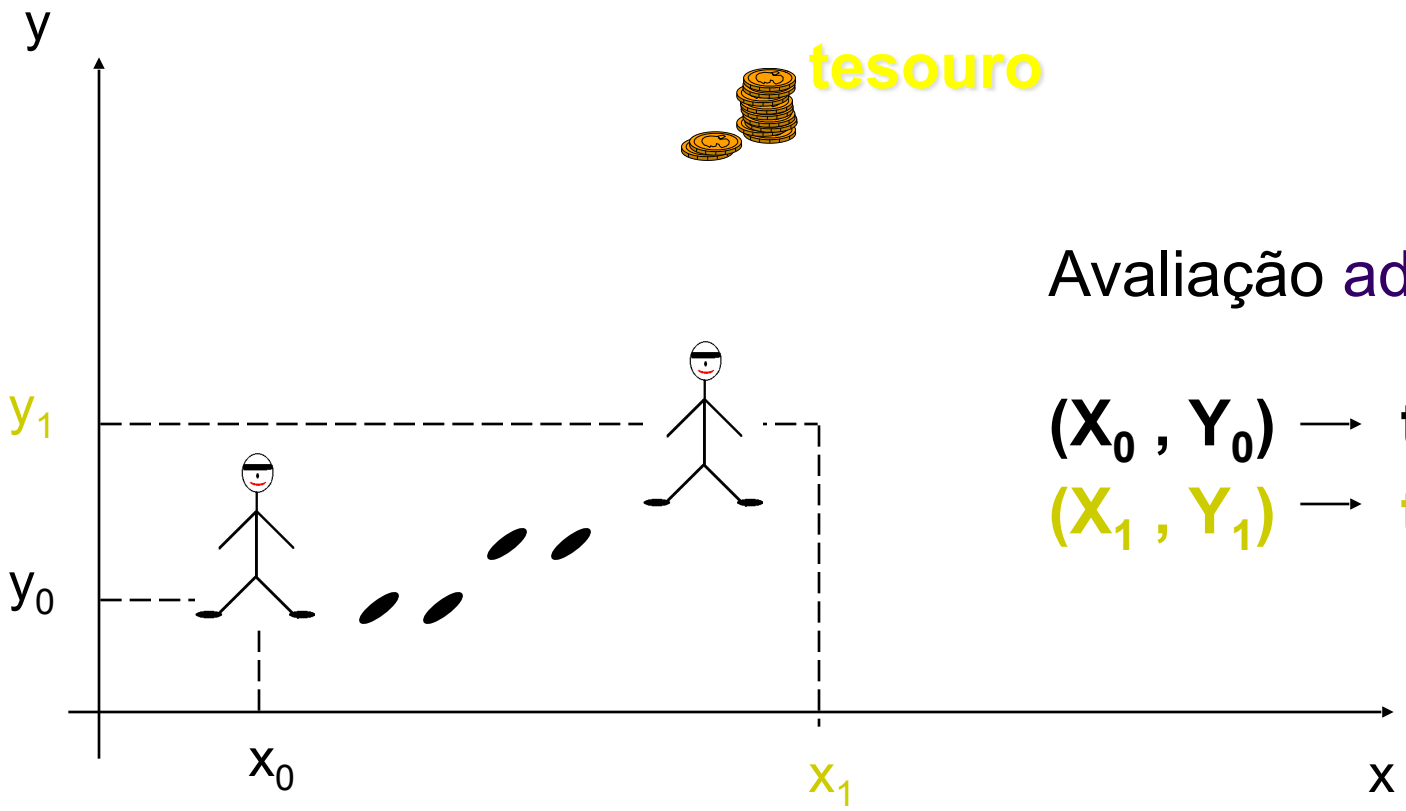


Avaliação adapta a busca

(X_0 , Y_0) → tá frio

Problema da Cabra Cega

Busca de objetivo escondido em uma área



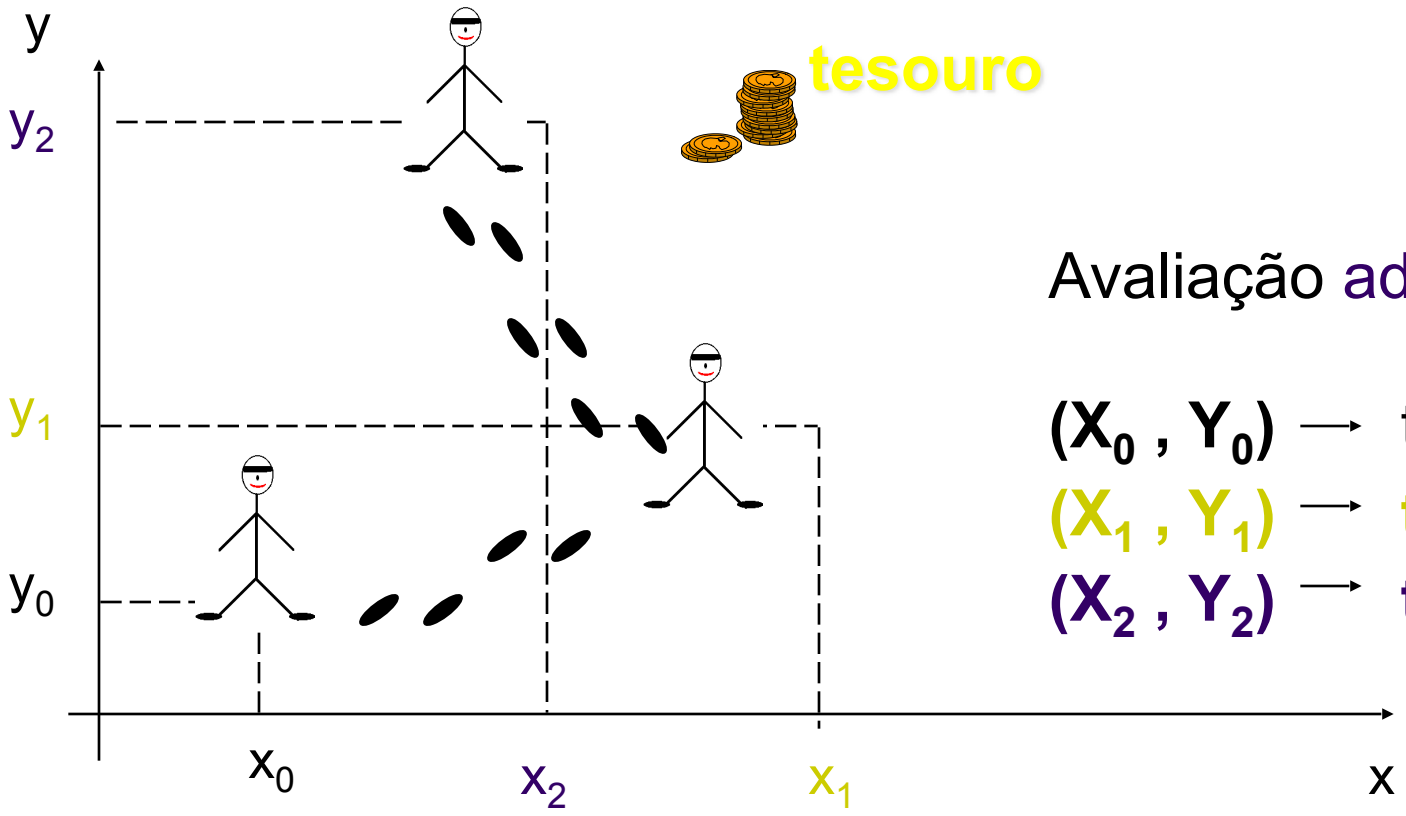
Avaliação adapta a busca

(X_0 , Y_0) → tá frio

(X_1 , Y_1) → tá morno

Problema da Cabra Cega

Busca de objetivo escondido em uma área



Avaliação adapta a busca

(X_0 , Y_0) → tá frio

(X_1 , Y_1) → **tá morno**

(X_2 , Y_2) → **tá quente!**

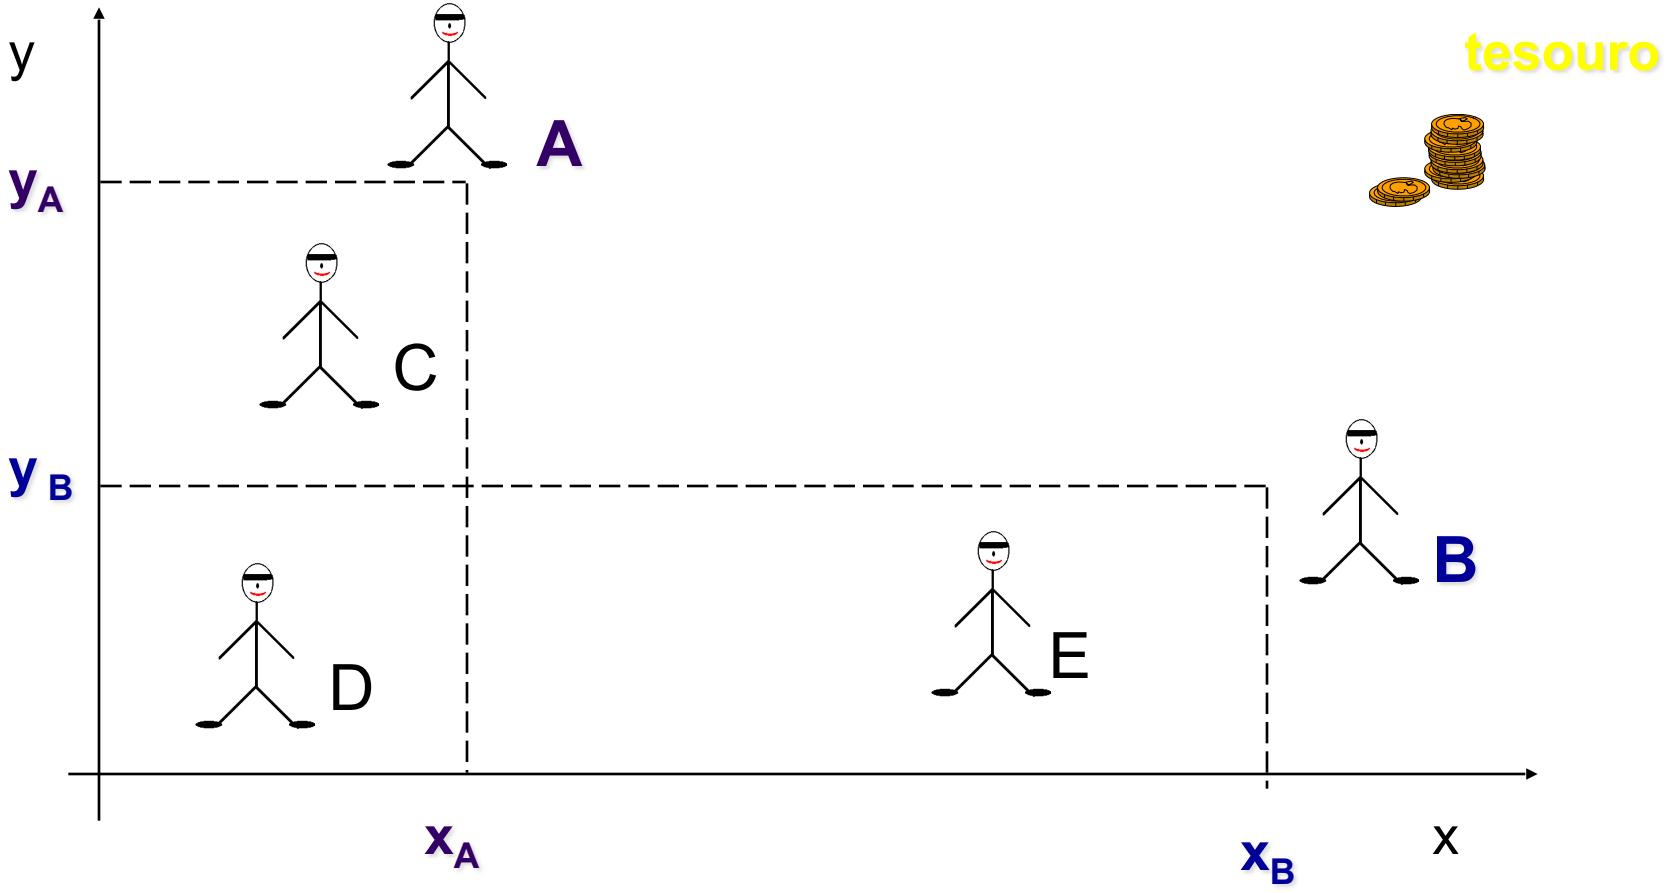
Problema da Cabra Cega

Área Muito Grande → Busca Paralela

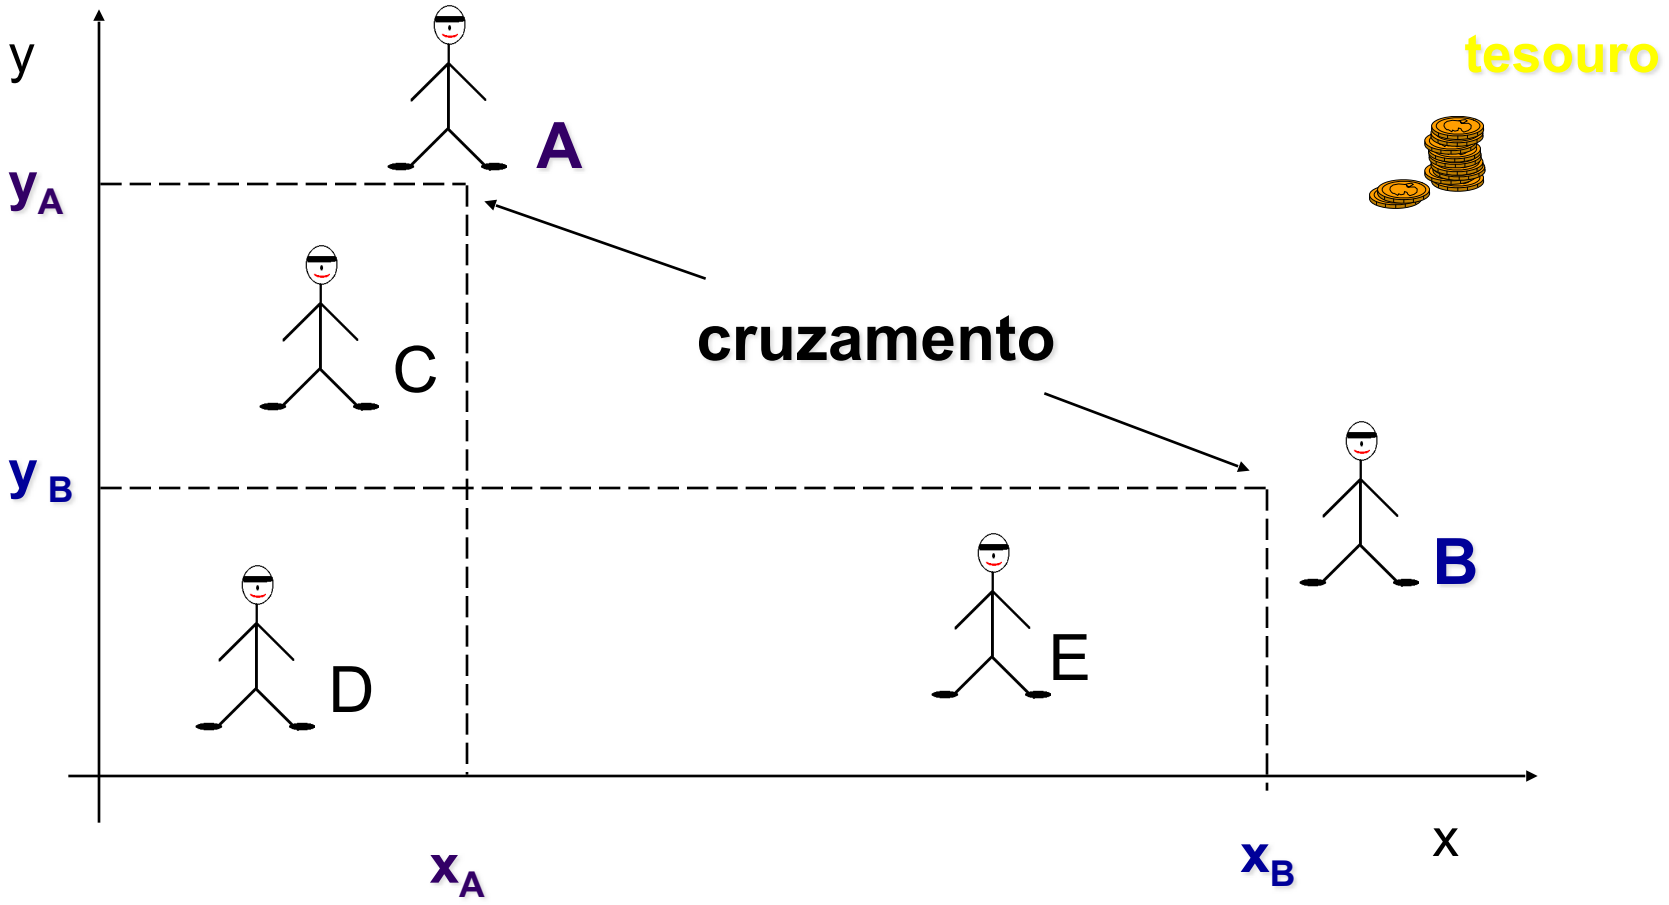


Problema da Cabra Cega

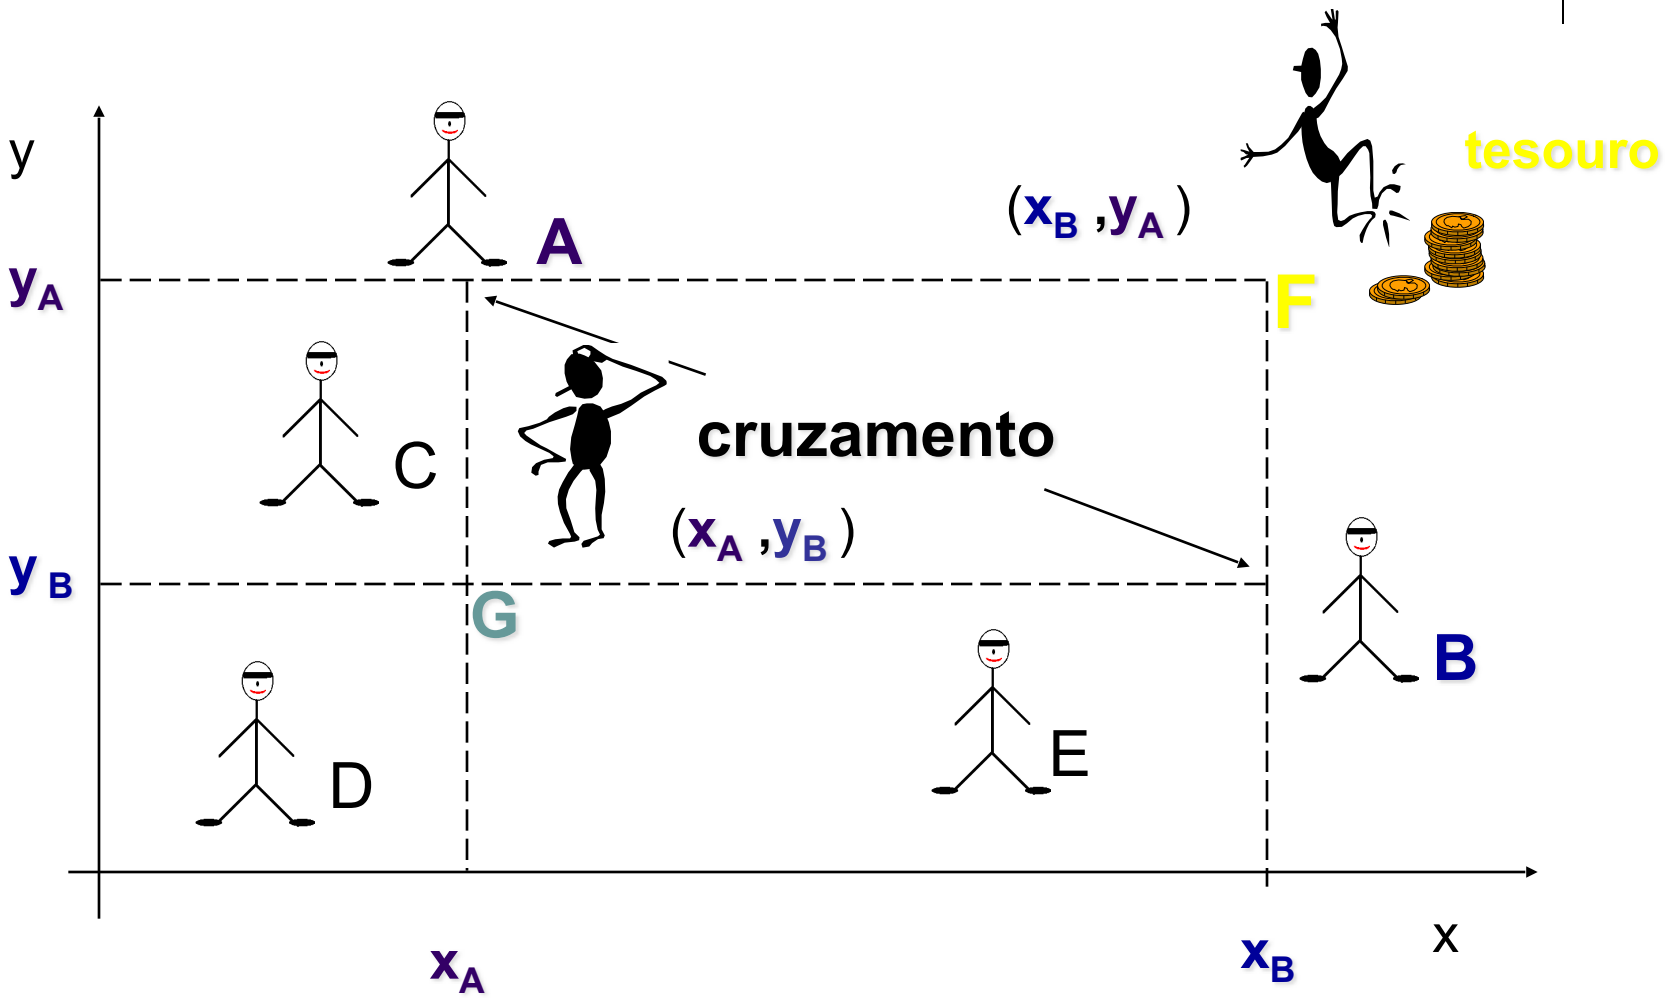
Área Muito Grande → Busca Paralela



Problema da Cabra Cega



Problema da Cabra Cega



Operações Básicas

- ***Seleção*:** privilegia os indivíduos mais aptos

Operações Básicas

- ***Seleção*:** privilegia os indivíduos mais aptos
- ***Reprodução:*** indivíduos (ex: palavras binárias) são reproduzidos com base na aptidão

Operações Básicas

- ***Seleção*:** privilegia os indivíduos mais aptos
- ***Reprodução:*** indivíduos (ex: palavras binárias) são reproduzidos com base na aptidão
- ***Crossover*:** troca de genes (pedaços de palavras)

Operações Básicas

- ***Seleção*: privilegia os indivíduos mais aptos**
- ***Reprodução:* indivíduos (ex: palavras binárias) são reproduzidos com base na aptidão**
- ***Crossover*: troca de genes (pedaços de palavras)**
- ***Mutação*: troca aleatória de um gene (bit da palavra)**

Exemplo

Problema:

➔ Achar o valor máximo para **f (x) = x^2** , **x** no limite de **0 a 63**.

Exemplo

Problema:

➔ Achar o valor máximo para **f (x) = x^2** , **x** no limite de **0 a 63**.

Representação da Solução:

➔ Palavras binárias representando sucessivas potências de 2.

011100 => Representa 28

110101 => Representa 53 (uma solução mais apta)

Seleção em Algoritmos Genéticos

População

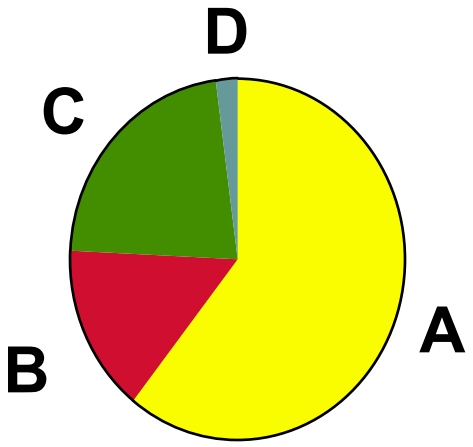
Cromossoma	Palavra	X	Aptidão (x^2)
A	100100	36	1296
B	010010	18	324
C	010110	22	484
D	000001	1	1

Seleção em Algoritmos Genéticos

População

Cromossoma	Palavra	X	Aptidão (x^2)
A	100100	36	1296
B	010010	18	324
C	010110	22	484
D	000001	1	1

Seleção

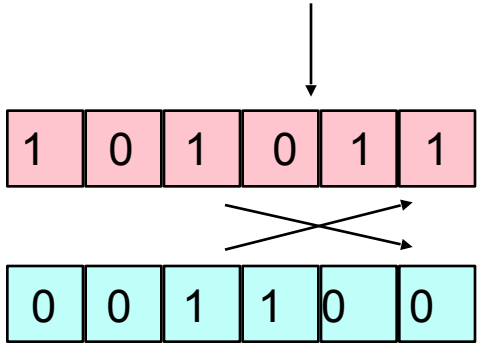


Probabilidade de Seleção ≈ **Aptidão do Cromossoma**

Operadores de Algoritmos Genéticos

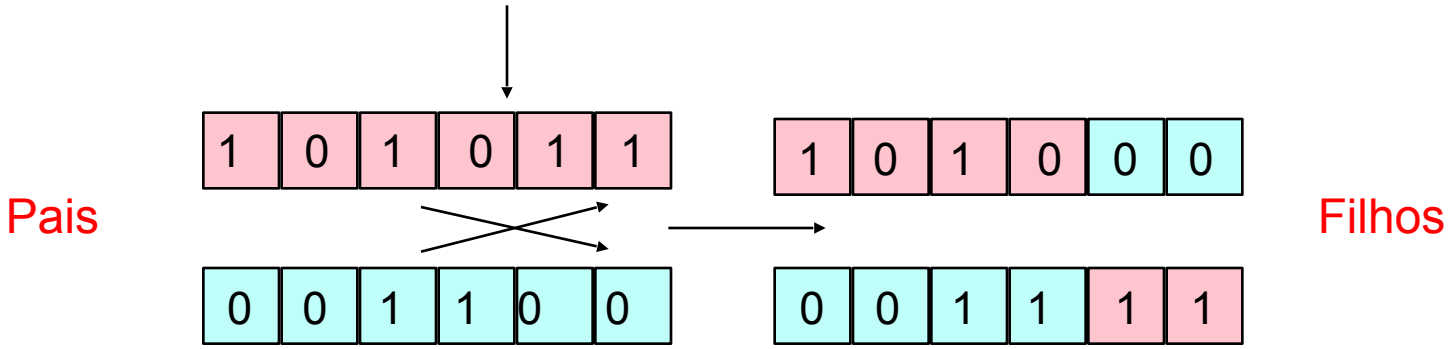
Crossover

Pais



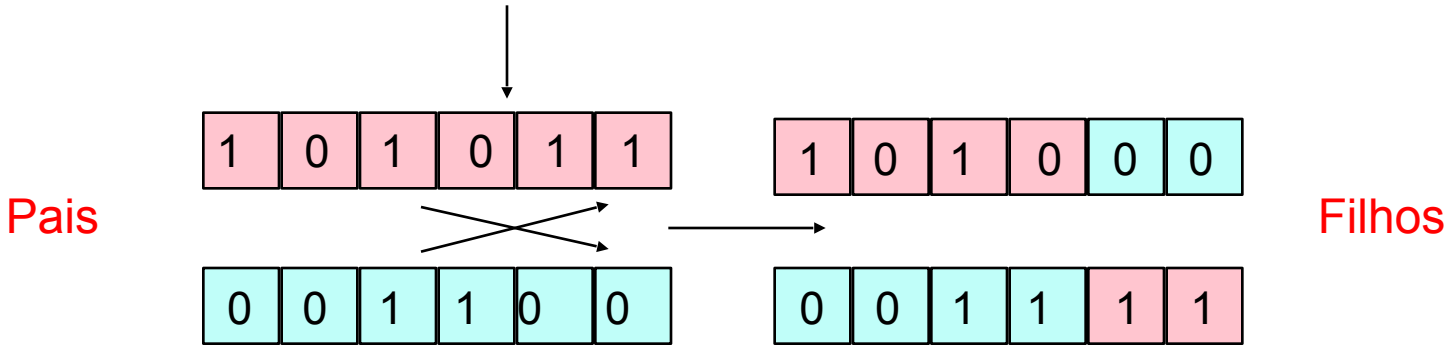
Operadores de Algoritmos Genéticos

Crossover

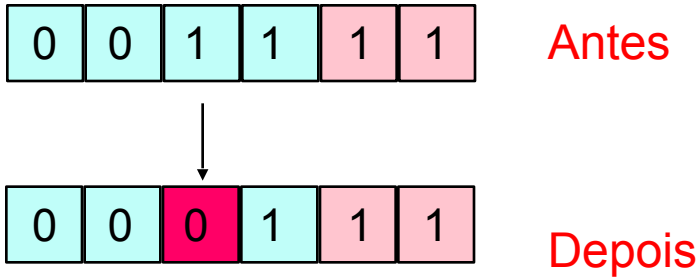


Operadores de Algoritmos Genéticos

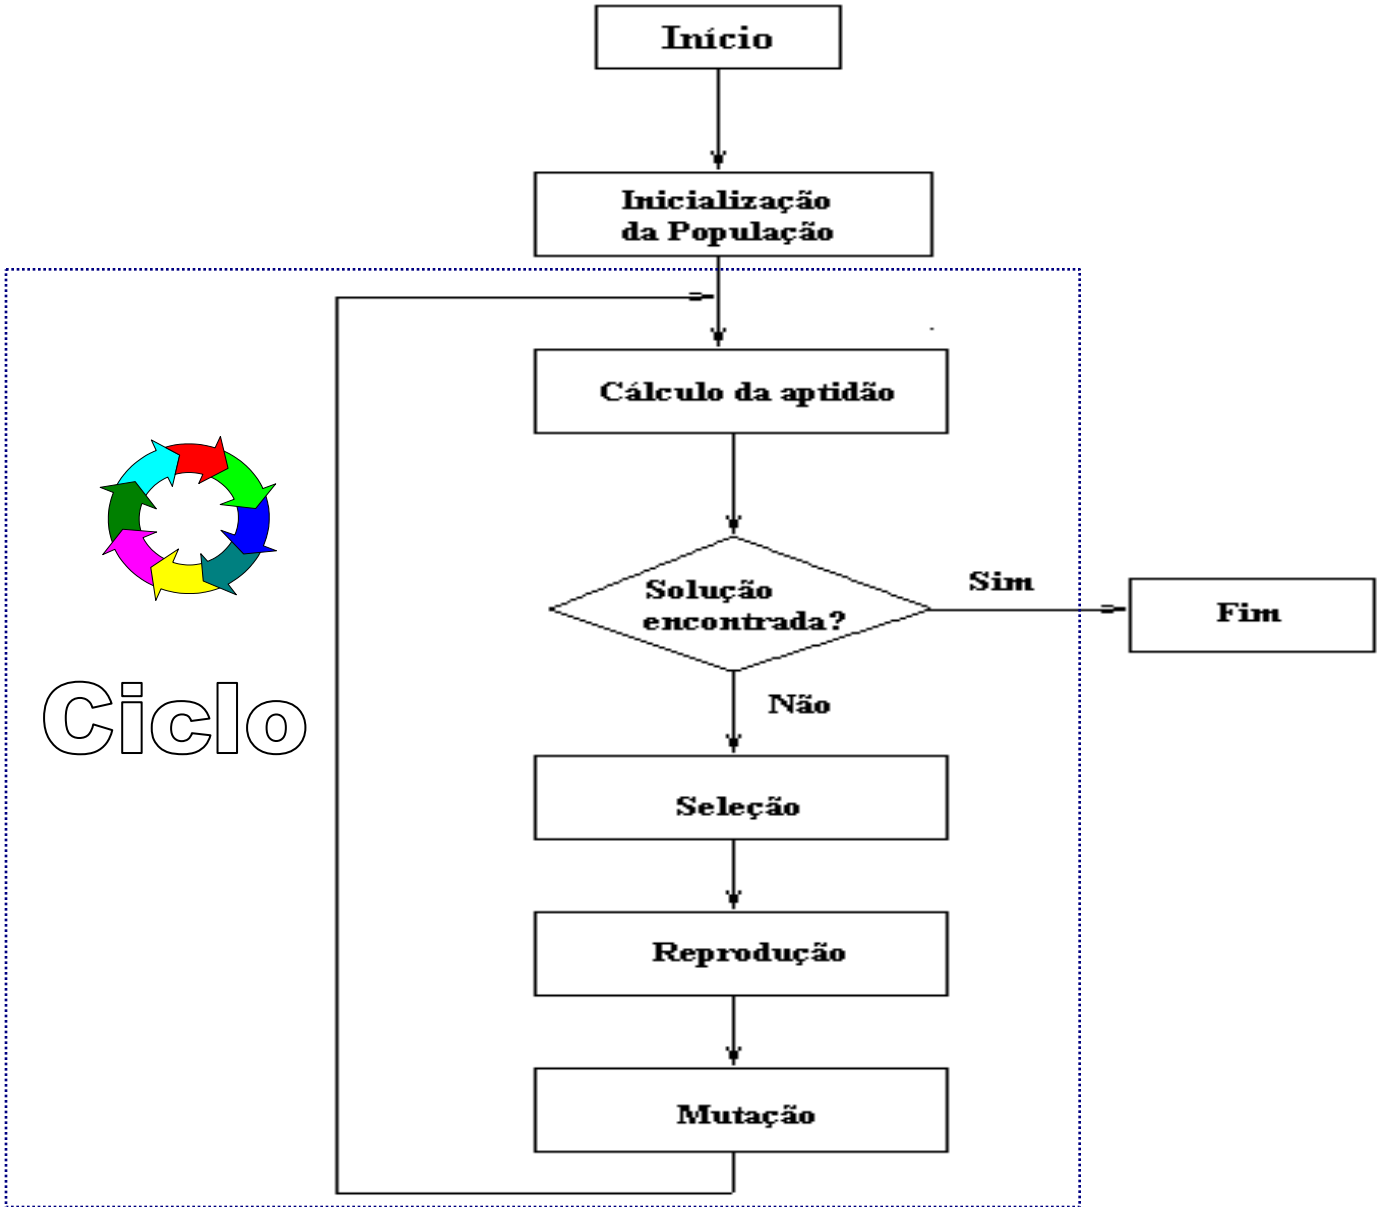
Crossover



Mutação



Fluxo do Algoritmo Genético



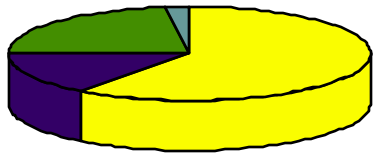
Ciclo do Algoritmo Genético

Cromossoma	Palavra	Aptidão
A	100100	1296
B	010010	324
C	010110	484
D	000001	1

Ciclo do Algoritmo Genético

Cromossoma	Palavra	Aptidão
A	100100	1296
B	010010	324
C	010110	484
D	000001	1

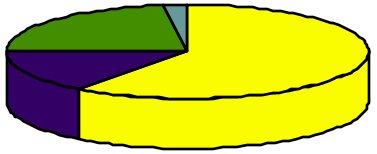
Pais



Ciclo do Algoritmo Genético

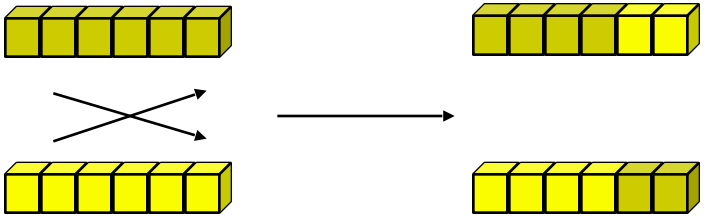
Cromossoma	Palavra	Aptidão
A	100100	1296
B	010010	324
C	010110	484
D	000001	1

Pais

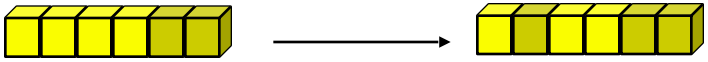


Reprodução

Crossover



Mutação



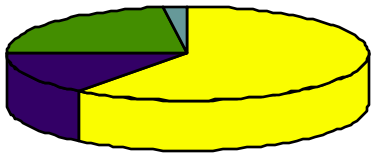
Ciclo do Algoritmo Genético

Avaliação dos Filhos

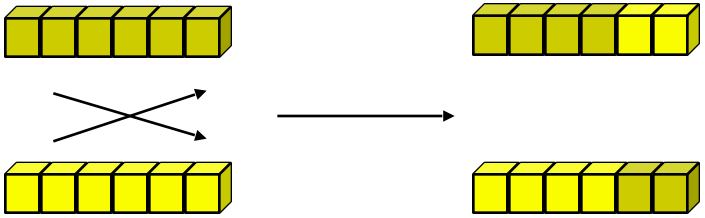
Cromossoma	Palavra	Aptidão
A	100100	1296
B	010010	324
C	010110	484
D	000001	1

Pais

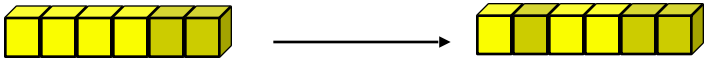
f( )



Crossover



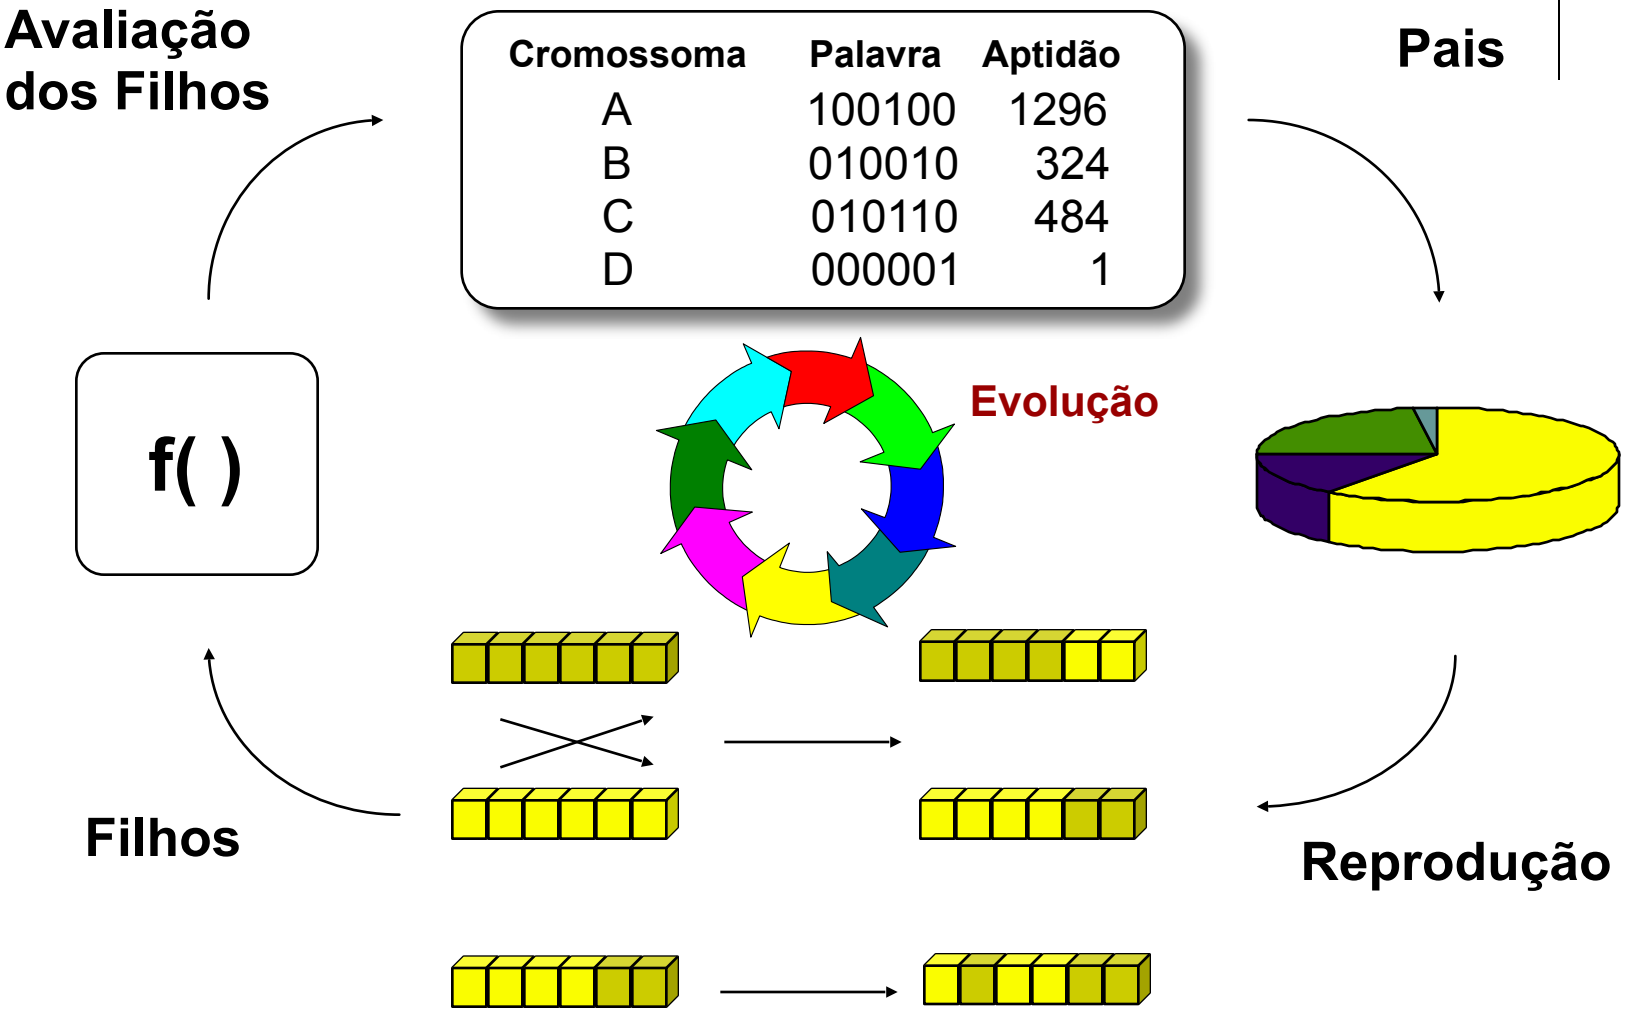
Mutação



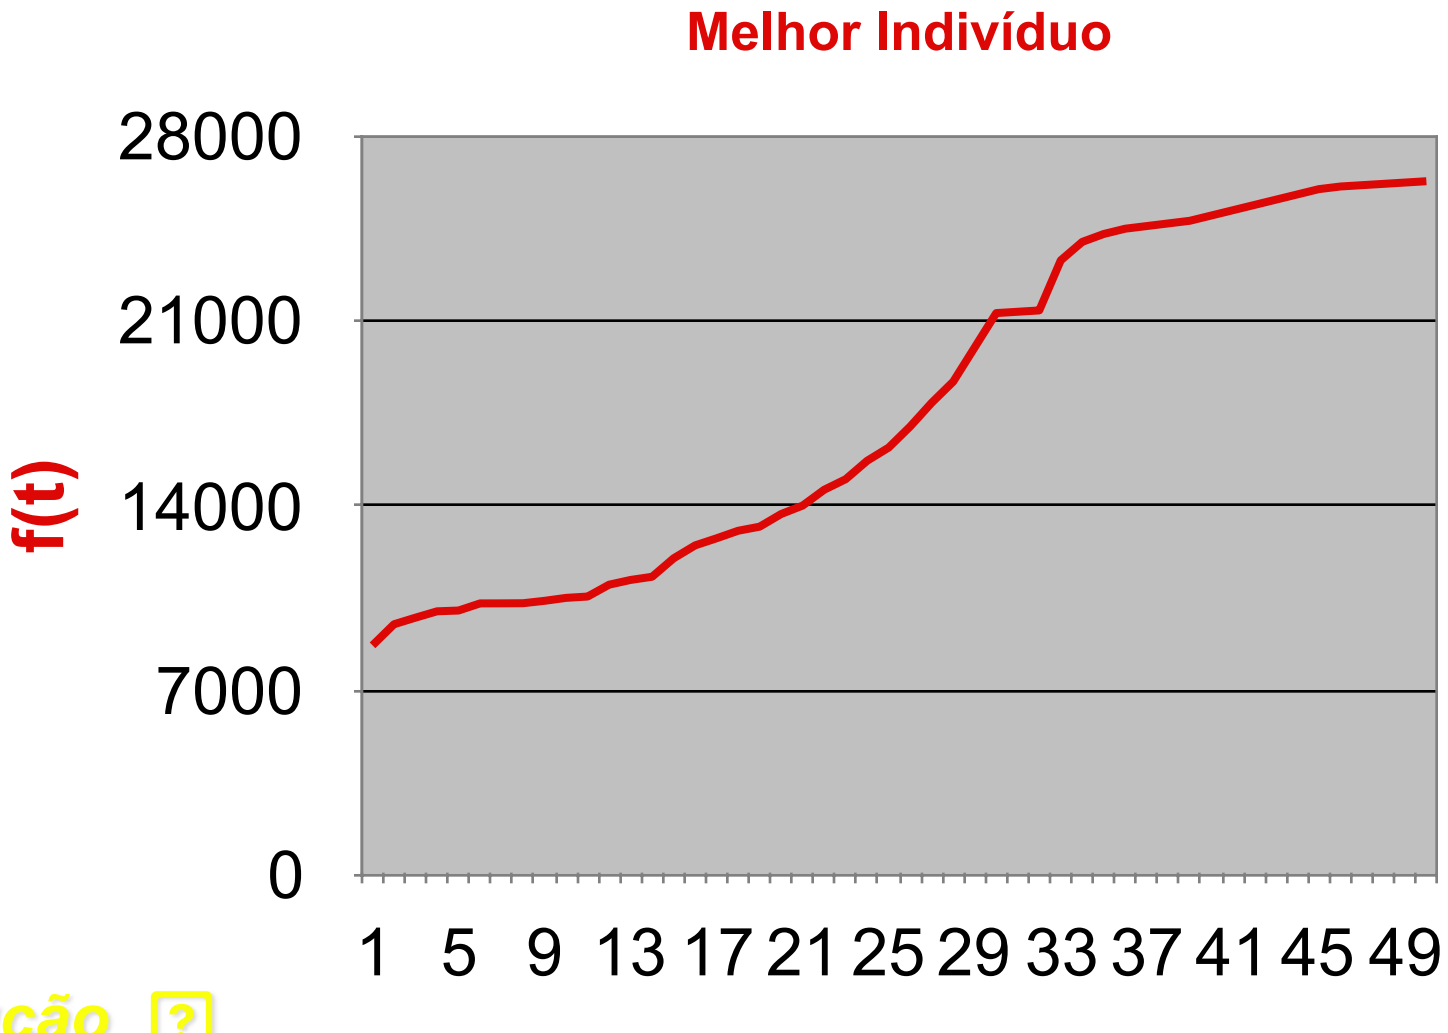
Filhos

Reprodução

Ciclo do Algoritmo Genético



Evolução dos Indivíduos



Evolução ?

Avaliação

Aplicado em problemas complexos de otimização – de difícil modelagem matemática, com variedade de regras e condições, ou com grande número de soluções a considerar.

Avaliação

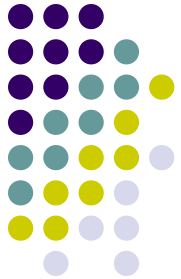
Vantagens

- Técnica de busca global (evita mínimos locais)
- Otimização de problemas complexos e mal estruturados
- Dispensa formulação matemática precisa do problema

Desvantagens

- Precisão na representação do cromossoma
- Evolução demorada em alguns problemas
- Modelagem depende do habilidade do especialista em GA

Aplicações Industriais



- **GENERAL ELECTRIC** - Otimização de Projeto de Motores DC
- **BRITISH GAS** - Otimização da Distribuição de Gás
- **BBN** - Roteamento de Telecomunicações
- **ATTAR** - Planejamento da Programação de TV

Aplicações Comerciais

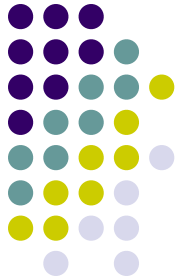


- **CAP VOLMAC** - Avaliação de Crédito e Análise de Risco
- **SEARCHSPACE** - Detecção de Fraude na Bolsa de Londres
- **IOC** - Planejamento dos Jogos Olímpicos
- **CAP Gemini** - Avaliação de Empréstimos e Financiamentos
- **GWI** - Modelagem Econômica
- **World Bank** - Geração de Regras de Negociação na Bolsa



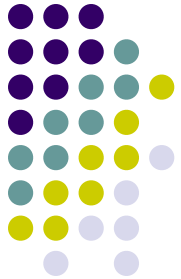
Desenvolvimento do AG

Componentes de um Algoritmo Genético



1. **Problema**
2. **Representação**
3. **Decodificação**
4. **Avaliação**
5. **Operadores**
6. **Parâmetros**

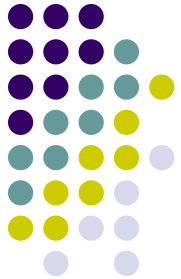
1. PROBLEMA



- **Estudo de Contexto do Problema:** Conhecer regras, restrições, objetivos, procedimentos em uso, etc.

- **GAs são indicados em problemas difíceis de otimização:**
  - **muitos parâmetros e variáveis;**
  - **mal estruturados: com condições e restrições, difíceis de serem modeladas matematicamente;**
  - **grandes espaços de busca onde não é possível a busca exaustiva.**

2. REPRESENTAÇÃO



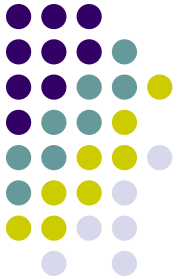
Representação é fundamental na modelagem de um GA e deve:

- **descrever o espaço de busca relevante ao problema;**
- **codificar geneticamente a "essência" do problema:**

  evolução do "código" ➡ evolução da solução
- **ser compatível com os operadores (crossover e mutação)**

  representação adequada ➡ evolução, otimização

2. REPRESENTAÇÃO

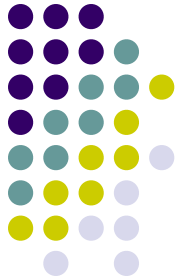


Tipo de Problema ↔ Representação

- **Numérico**
- **Ordem**
- **Grupo**
- **Inteiro**
- **Misto**

- **Binário, Real**
- **Lista**
- **Vetor**
- **Inteiro**
- **Mista**

Real representado por Binário



- Primeiro tipo de representação em Algoritmos Genéticos
- Número real é codificado através de um número binário de K bits
- Representação binária descreve um real em detalhes (genes):

$$13 \text{ em binário} = 1101 = 1x2^3 + 1x2^2 + 0x2^1 + 1x2^0 =$$

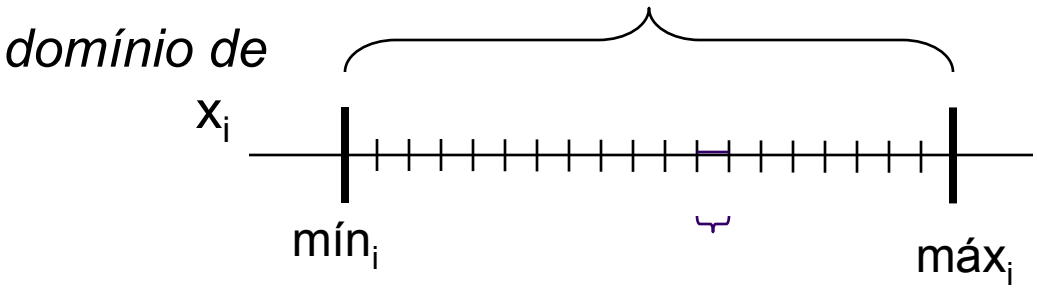
$$8 + 4 + 1$$

BINÁRIO CODIFICANDO REAL

Aspectos importantes:

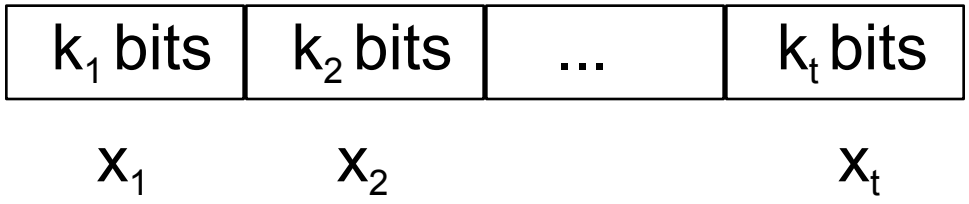
- ✶**variáveis** do problema (x_1 , x_2 , ... , x_t)
- ✶**domínio** de valores: $x_i \in (mín_i, máx_i)$ em R
- ✶**precisão**: *p* casas decimais

$(máx_i - mín_i) \times 10^p$ + 1 diferentes soluções



Precisão ? $1/10^p$

Representação:



onde,

$$2^{k_i} \geq (máx_i - mín_i) \times 10^p \rightarrow \text{Precisão} = \frac{(máx_i - mín_i)}{2^{k_i} - 1}$$

Decodificação para Real:

$$x_{i\ real} = x_{i\ bin} \cdot \frac{(máx_i - mín_i)}{2^{k_i} - 1} + mín_i$$

$x_{i\ bin}$: Binário na base 10

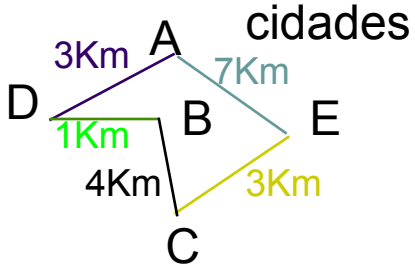
se $x_{ibin}=(0\ 0\ ...\ 0)$ → $x_{i\ real} = mín_i$

se $x_{ibin}=(1\ 1\ ...\ 1)$ → $x_{i\ real} = máx_i$

3. DECODIFICAÇÃO

Construir a solução para o problema a partir de um cromossoma:

Cromossomas "representam" soluções.

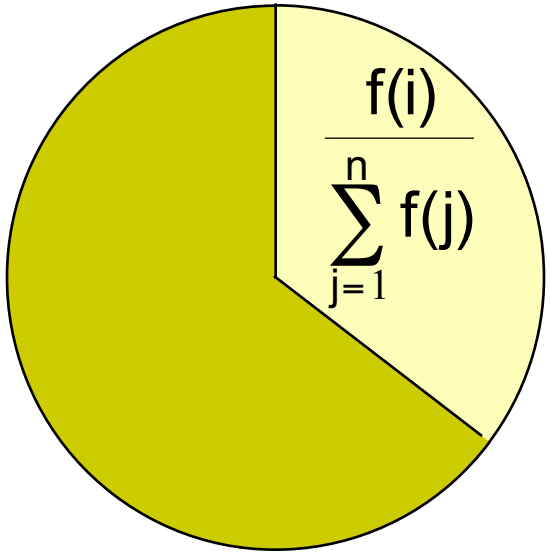
Cromossoma	DECODIFICAÇÃO	Solução
0011011	bin ➡ inteiro	x=27
0011011	$x=27 \times 10/(2^7-1)$	$x=2,1 \quad x \in [0,10]$ 1 casa decimal
ADBCE		rota A→D→B→C→E

4. AVALIAÇÃO

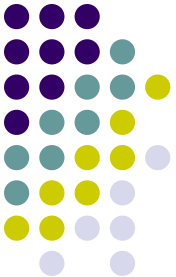
Elo entre o algoritmo genético e o problema.

f(cromossoma) = medida numérica de aptidão

Chances de seleção são proporcionais à aptidão.



Seleção pela Roleta



Objetivo: *Selecionar indivíduos aleatoriamente, proporcionando maiores chances de reprodução aos mais aptos.*

Método por Computador

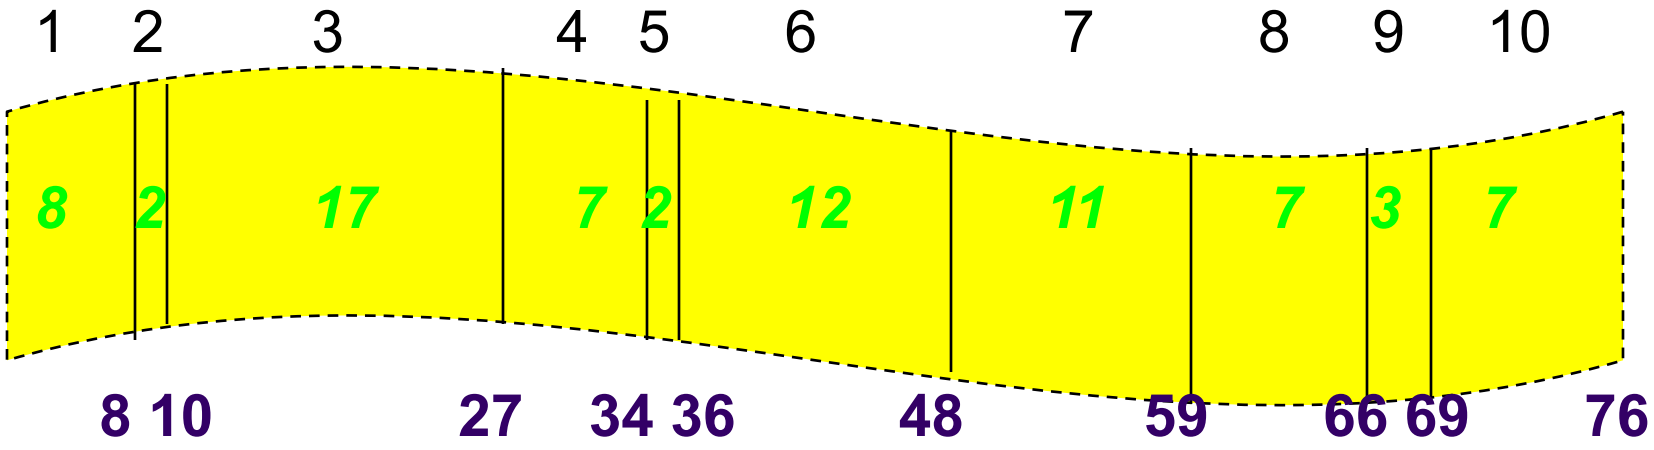
- Encontre a soma da aptidão de todos os membros da população
  $\mathbf{A_T = \sum A_i}$ (0 ó i ó pop_size-1)
- Gere um número aleatório **0 ó rand ó A_T**
- Pegue o primeiro membro da população I_k cuja aptidão somada às aptidões dos membros precedentes é maior ou igual a rand.

$$\mathbf{\sum A_i \text{ ò rand}} \quad (i < k)$$

Exemplo da Roleta

Cromossoma	1	2	3	4	5	6	7	8	9	10
Aptidão	*8*	*2*	*17*	*7*	*2*	*12*	*11*	*7*	*3*	*7*
$\sum A_i$	8	10	27	34	36	48	59	66	69	76

Número Aleatório	23	49	76	13	1	27	57
Selecionado	3	7	10	3	1	3	7



5. OPERADORES

Atuam no processo de criação de novos indivíduos (descendentes):

1. **Crossover**
2. **Mutação**
3. **Operadores específicos ao problema (heurísticos)**

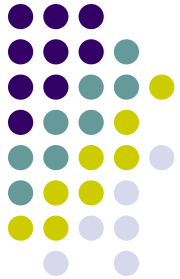
Crossover de 1 ponto de corte

- A cauda de dois cromossomas são trocadas a partir de posição escolhida aleatoriamente
- Taxa de Crossover : entre **60% e 90%**
  - Teste Verdadeiro — **Efetua Cruzamento**
  - Teste Falso — **Copia os Genitores**

	Cabeça			Cauda		
P_1	1	0	1	1	0	1
P_2	0	0	1	1	0	0
F_1	1	0	1	1	0	0
F_2	0	0	1	1	0	1

ponto de corte aleatório ?

Mutação por inversão de bit



- Inverte cada gene de um cromossoma se o teste de probabilidade for verdadeiro
- Taxa Mutação: entre **0,1% e 5%**
  - Teste Verdadeiro ? **troca bit**
  - Teste Falso ? **mantém bit**
  - **0,8% (0,008)**

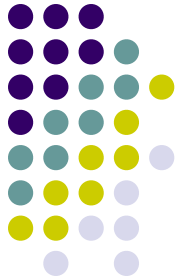
Cromossoma				*Número Aleatório*				*Novo Cromossoma*			
1	0	1	0	0,801	0,102	0,266	0,373	1	0	1	0
1	1	0	0	0,128	0,96	0,005	0,84	1	1	1	0
0	0	1	0	0,768	0,473	0,894	0,001	0	0	1	1

6. PARÂMETROS

- TAMANHO_POPULAÇÃO
- NÚMERO_GERAÇÕES
- TAXA_CROSSOVER
- TAXA_MUTAÇÃO

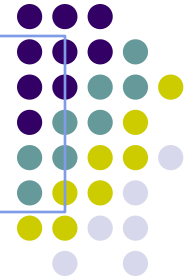
...

Desenvolvimento de um Algoritmo Genético



```
procedure  algoritmo_genético
begin
        t = 0                                   ; primeira geração
        inicializa P(t)                         ; população inicial aleatória
        avalia P(t)                             ; calcula f(i) p/ cada indivíduo
        while (not condição_parada) do
        begin
                t = t + 1                       ; próxima geração
                seleciona P(t) de P(t-1)
                altera P(t)                     ; crossover e mutação
                avalia P(t)                     ; calcula f(i) p/ cada indivíduo
        end
end
```

Sistemas de Desenvolvimento



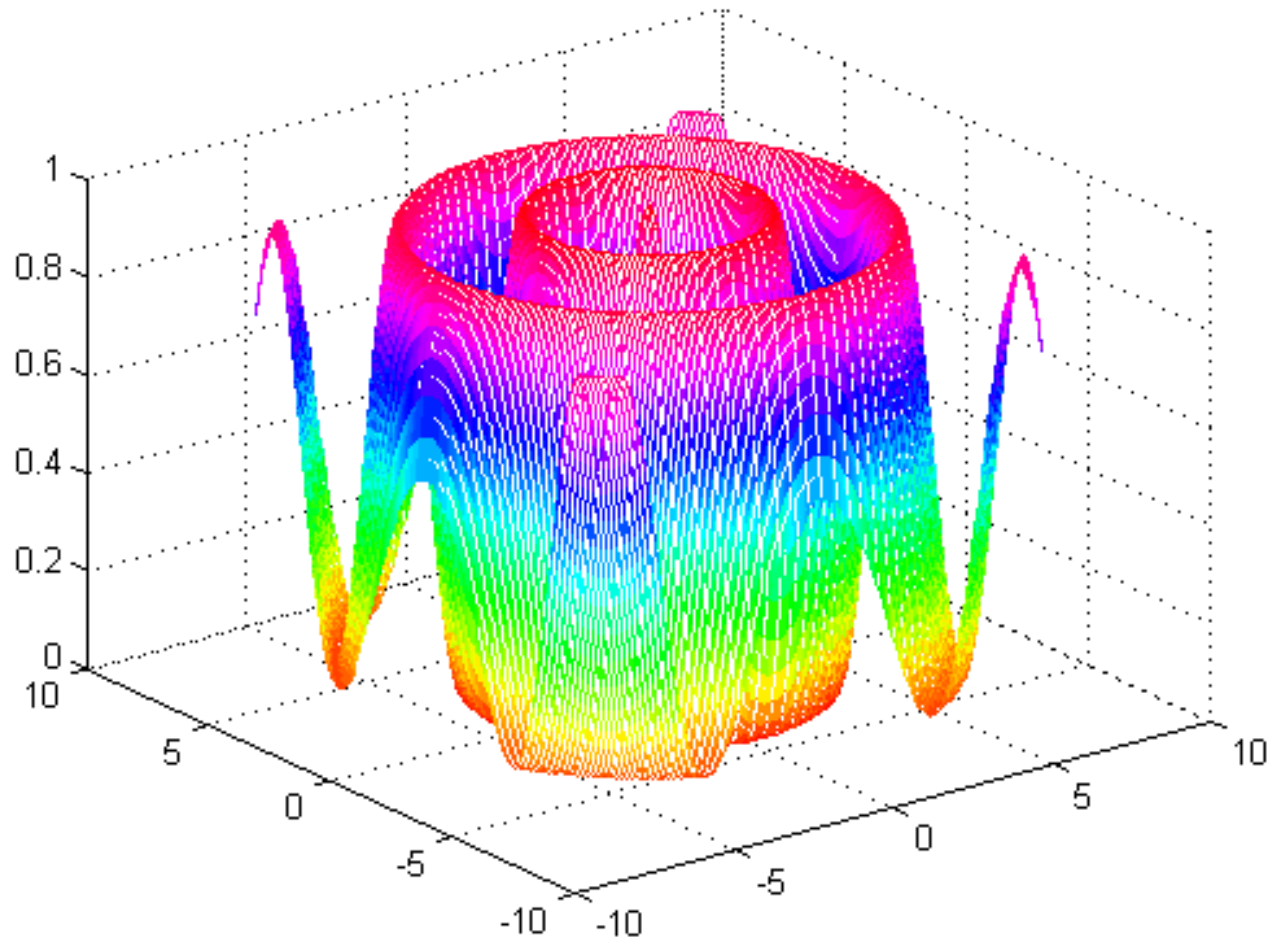
ICA • ICADEMO

ICA • WinGenesis

- GENOCOP
- GeneHunter
- Evolver 4.0
- Open Beagle
- Sugal
- GACOM: Biblioteca de Componentes (C#)

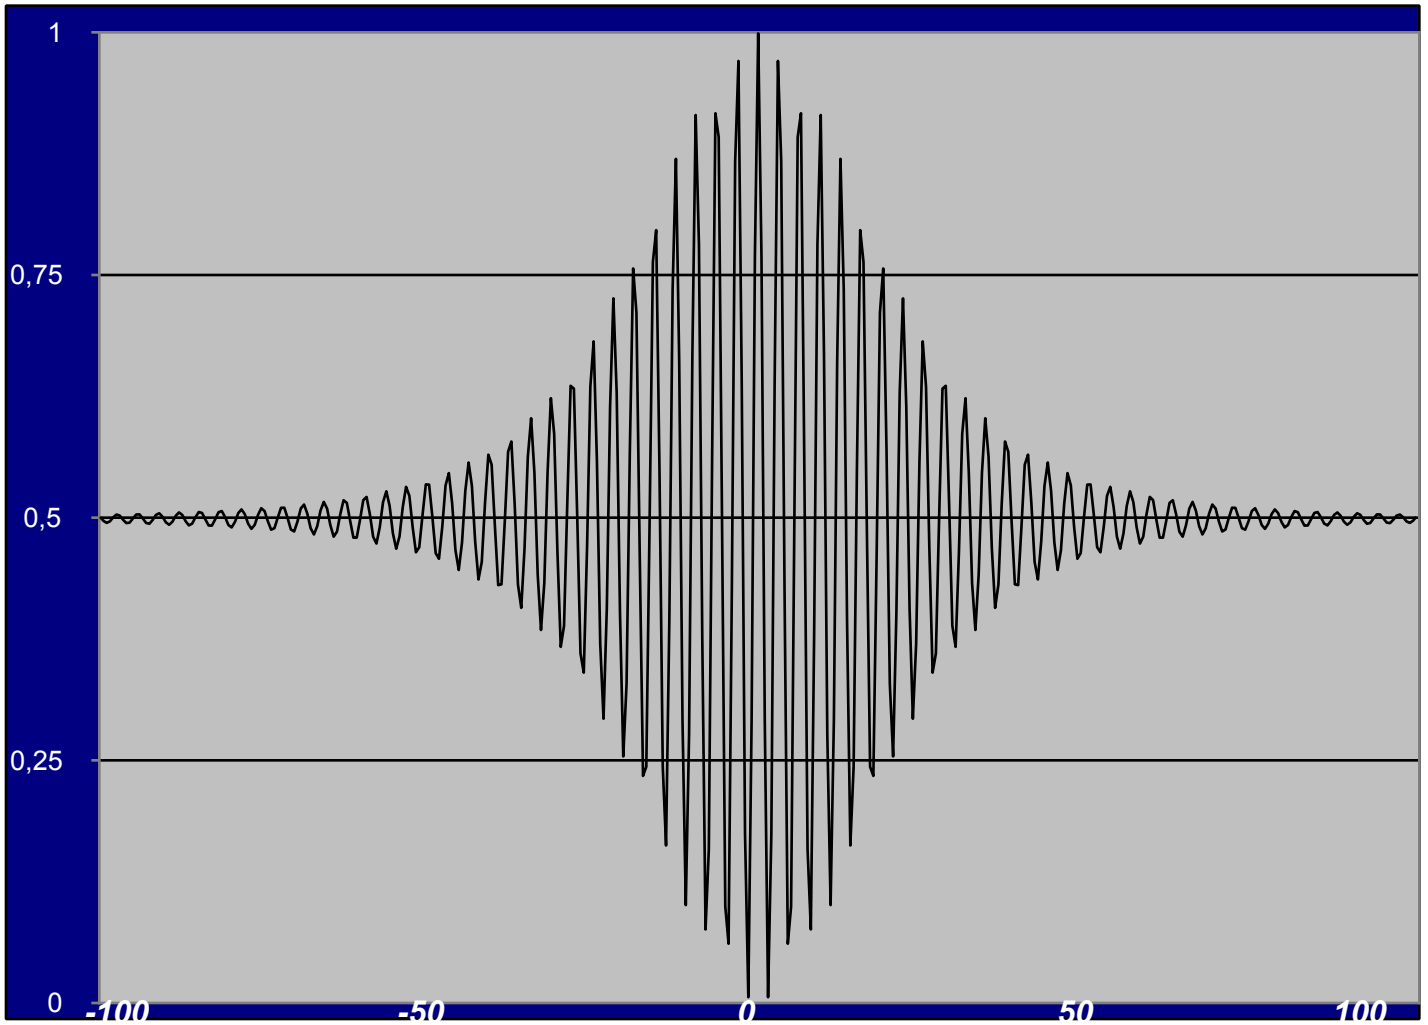
ICA

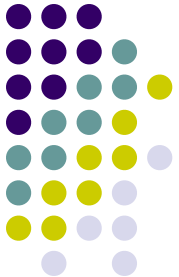
Desenvolver um AG para Maximizar a função F6:



Função *F6(x,y)*

F6(x,0)





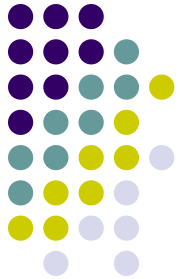
- **Módulo de Avaliação**
  - **Função de Avaliação:** *Função binária F_6*
- **Módulo de População**
  - **Técnica de Representação:** *Binária 44 bits*
  - **Técnica Inicialização da População:** *Aleatória*
  - **Técnica Eliminação da População:** *Elimina todos – o mais apto (Elitismo)*
  - **Técnica de Seleção de Genitores:** *Roleta*
  - **Técnica de Aptidão:** *Aptidão é a avaliação*
  - **Population Size:** *100*
- **Módulo de Reprodução**
  - **Operadores:** *Crossover 1 ponto & Mutação*
    - *Taxa Mutação:* *0,008*
    - *Taxa Crossover:* *0,65*

Características da F6

$$F6(x,y) = 0{,}5 - \frac{(\text{sen}\ \sqrt{x^2 + y^2}\ )^2 - 0{,}5}{(1{,}0 + 0{,}001\ (x^2 + y^2\ ))^2}$$

- Objetivo: Maximizar F6
- Uma única solução ótima: *F6(0,0)=1*
- Difícil de otimizar: vários mínimos locais

Representação

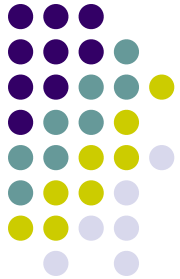


- Binária codificando real
- 2 Variáveis: x, y
- Domínio: x,y $\in$ [-100, +100]
- Precisão: 4 a 5 casas decimais
- K_i=22 ? total de 44 bits

Exemplo

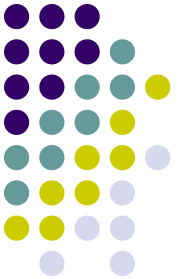
- **Cromossoma:**
  00001010000110000000011000101010001110111011
- **Dividido em x e y:**
  00001010000011000000001 10001010100011101110 11
- **Convertidos para base 10:**
  165377 e 2270139
- **Multiplicados por: $200/2^{22}-1$**
  7,885791751335085 e 108,24868875710696
- **Somados a mín:**
  x=-92,11420824866492 e y=8,248688757106959
- **Aplicados a F6(x,y):**
  F6(x,y)=0,5050708

Módulo de População



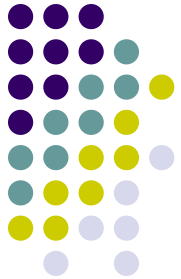
- **Técnica Inicialização da População:** *Aleatória*
  - *Geração aleatória de palavras de 44 bits*
- **Técnica de Aptidão:** *Aptidão é a avaliação*
  - *Aptidão é numericamente igual à avaliação*
- **Técnica de Seleção de Genitores:** *Roleta*

Parâmetros



- Tamanho da População: Exemplo
  pop_size **100**
- Número de Gerações:
  num_ger **40**
- Total de Indivíduos:
  total_ind = pop_size x num_ger **4000**

Parâmetros



- Tamanho da População: Exemplo
  pop_size **10**
- Número de Gerações:
  num_ger **400**
- Total de Indivíduos:
  total_ind = pop_size x num_ger **4000**